

Uvod v globoko učenje in grafovske nevronske mreže

Ljupčo Todorovski

Univerza v Ljubljani, Fakulteta za matematiko in fiziko
Institut Jožef Stefan, Odsek za tehnologije znanja (E8)

Maj 2023

- 1 Uvod v globoko učenje
 - Osnovne definicije
 - Običajne funkcije aktivacije
 - Vzratno razširjanje napake, *back propagation*
 - Delovanje nevronske mreže
- 2 Grafske nevronske mreže
 - Od grafa do strukture GNM
 - Struktura in učenje GNM

Nevroni in sinapse


Gradnika nevronske mreže (NM)

- Nevron: ima **stanje** $v \in \mathbb{R}$ in **izhod** $y \in \mathbb{R}$
- Sinapsa: povezava med nevroni, ki ima **utež** $w \in \mathbb{R}$
- Sinapse določajo **strukturo** (tudi arhitekturo, topologijo) NM

Izvajanje nevronske mreže

- Vhodni podatki spremenijo stanje in izhode izbranih, vhodnih nevronov
- Spremenjeni izhodi nevronov se prenašajo po sinapsah
- Nevron, ob spremembi vhodov na sinapsah, izračuna (spremeni) izhod
- Izračun se nadaljuje, dokler se izhodi nevronov ne ustalijo

Funkcija nevrona in funkcija aktivacije ϕ



Vektorska notacija: $\mathbf{x} = (1, x_1, x_2, \dots, x_m)^T$ in $\mathbf{w} = (w_0, w_1, \dots, w_m)^T$.

Struktura usmerjenih nevronske mreže

Nevroni urejeni v plasteh z indeksi od 0 do $L + 1$

- Vhodna plast 0: en nevron za vsako vhodno (numerično) spremenljivko
- Izhodna plast $L + 1$
 - Regresija: en izhodni nevron
 - Klasifikacija: en izhodni nevron za vsako vrednost ciljne spremenljivke
- $L \geq 0$ skritih, *hidden* plasti

Sinapse in uteži

- Med nevroni v eni plasti ni povezovalnih sinaps
- Sosednji plasti $l - 1$ in l za $l = 0 \dots L$ polno povezani: sinapse povezujejo vsak nevron plasti $l - 1$ z vsakim nevronom plasti l


Primer usmerjene nevronske mreže: Dve skriti plasti

Vhodna plast 0

Skrita plast 1

Skrita plast 2


Izhodna plast 3



Koliko uteži ima ta usmerjena nevronska mreža?

Sigmoidni funkciji aktivacije v usmerjenih NM

- Logistična $\phi(v) = \frac{1}{1+e^{-v}}$, za odvod velja $\phi'(v) = \phi(v)(1 - \phi(v))$
- Hiperbolična $\phi(v) = \tanh v$, za odvod velja $\phi'(v) = 1 - \phi(v)^2$



Funkcija aktivacije za izhodno plast klasifikacijske NM

$$\phi_{softmax}(v) = \frac{e^v}{\sum_k e^{v_k^{(L+1)}}}$$

- Indeks k gre skozi vse nevrone izhodne plasti $L + 1$
- Zagotovi, da je seštevek izhodov vseh nevronov izhodne plasti 1
- Zato lahko **izhode interpretiramo kot verjetnosti**, torej
- Za $D_Y = \{v_1, v_2, \dots, v_c\}$ je izhod $y_k = P(Y = v_k)$, $k = 1 \dots c$

Notacija v izpeljavah in formulah

Indeksi plasti nevronov

- 0: vhodna plast, plast vhodnih nevronov
- $L + 1$: izhodna plast, plast izhodnih nevronov
- $1, 2, \dots, L$: skrite plasti, plasti skritih nevronov

Uteži sinaps ter stanja in izhodi nevronov

- $w_{ji}^{(l)}$ je **utež** sinapse med j -tim nevronom plasti $l - 1$ in i -tim nevronom plasti l
- $v_i^{(l)}$ je **stanje** i -tega nevrona plasti l , velja torej $v_i^{(l)} = \sum_j w_{ji}^{(l)} y_j^{(l-1)}$
- $y_i^{(l)}$ je **izhod** i -tega nevrona plasti l , $y_i^{(l)} = \phi \left(v_i^{(l)} \right)$

Funkcija izgube za regresijo in njen odvod

Kvadratna napaka

$$E = \frac{1}{2} \sum_i (y_i - \hat{y}_i)^2 = \frac{1}{2} \sum_i \left(y_i - y_i^{(L+1)} \right)^2,$$

ker velja $\hat{y}_i = y_i^{(L+1)}$.

Odvod funkcije izgube

$$\frac{\partial E}{\partial \hat{y}_i} = -(y_i - \hat{y}_i) = -\left(y_i - y_i^{(L+1)} \right)$$

Funkcija izgube za klasifikacijo

Prečna entropija H med

- Opazovano porazdelitvijo p vrednosti ciljne spremenljivke Y
- Porazdelitvijo q vrednosti Y , ki jo napove NM, $q(v_i) = y_i^{(L+1)}$

$$E = H(p, q) = - \sum_{v_i \in D_Y} p(v_i) \log_2 q(v_i) = - \sum_{v_i \in D_Y} p(v_i) \log_2 y_i^{(L+1)}$$

Za podan učni primer z vrednostjo ciljne spremenljivke $Y = v_m$

$$E = -\log_2 q(v_m) = -\log_2 y_m^{(L+1)},$$

ker velja $p(v_m) = 1, \forall v_i \in D_Y, v_i \neq v_m : p(v_i) = 0$.

Odvod prečne entropije

$$\frac{\partial E}{\partial \hat{y}_i} = \begin{cases} 0 & ; i \neq m \\ -\frac{1}{y_m^{(L+1)} \log 2} & ; i = m \end{cases}$$

Gradienti izgube E za izhodno plast

$$\hat{y}_i = y_i^{(L+1)} = \phi \left(v_i^{(L+1)} \right), \quad v_i^{(L+1)} = \sum_j w_{ji}^{(L+1)} y_j^{(L)}$$

$$\begin{aligned} \frac{\partial E}{\partial w_{ji}^{(L+1)}} &= \frac{\partial E}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial v_i^{(L+1)}} \frac{\partial v_i^{(L+1)}}{\partial w_{ji}^{(L+1)}} \\ &= - \left(y_i - y_i^{(L+1)} \right) \phi' \left(v_i^{(L+1)} \right) \frac{\partial \sum_k w_{ki}^{(L+1)} y_k^{(L)}}{\partial w_{ji}^{(L+1)}} \\ &= - \left(y_i - y_i^{(L+1)} \right) \phi' \left(v_i^{(L+1)} \right) y_j^{(L)} \end{aligned}$$

$$\Delta w_{ji}^{(L+1)} = \eta \left(y_i - y_i^{(L+1)} \right) \phi' \left(v_i^{(L+1)} \right) y_j^{(L)}$$

Gradienti izgube za uteži skritih plasti, posredno odvajanje

$$\frac{\partial E}{\partial w_{ji}^{(l)}} = \frac{\partial E}{\partial y_i^{(l)}} \frac{\partial y_i^{(l)}}{\partial v_i^{(l)}} \frac{\partial v_i^{(l)}}{\partial w_{ji}^{(l)}} = \frac{\partial E}{\partial y_i^{(l)}} \phi'(v_i^{(l)}) y_j^{(l-1)}$$

Trik za izračun $\partial E / \partial y_i^{(l)}$ iz $\partial E / \partial y_k^{(l+1)}$

$$\begin{aligned} \frac{\partial E}{\partial y_i^{(l)}} &= \sum_k \frac{\partial E}{\partial v_k^{(l+1)}} \frac{\partial v_k^{(l+1)}}{\partial y_i^{(l)}} \\ &= \sum_k \frac{\partial E}{\partial y_k^{(l+1)}} \frac{\partial y_k^{(l+1)}}{\partial v_k^{(l+1)}} \frac{\partial v_k^{(l+1)}}{\partial y_i^{(l)}} \\ &= \sum_k \frac{\partial E}{\partial y_k^{(l+1)}} \phi'(v_k^{(l+1)}) w_{ik}^{(l+1)} \end{aligned}$$

Gradienti izgube za uteži skritih plasti

$$\Delta w_{ji}^{(l)} = \eta \phi' \left(v_i^{(l)} \right) y_j^{(l-1)} \sum_k \frac{\partial E}{\partial y_k^{(l+1)}} \phi' \left(v_k^{(l+1)} \right) w_{ik}^{(l+1)}$$

- Iteracija pravila od skrite plasti L do skrite plasti 1
- V vhodni plasti 0 upoštevamo $y_i^{(0)} = x_i$, t.j., vrednost spremenljivke X_i


Stohastična različica učnega algoritma

Osnovna ideja: vzorčenje primerov


- Učenje v **šaržah** oz. **batch-ih** primerov, velikost šarže je nadparameter
- V vsaki **iteraciji** izberemo šaržo za vzratno razširjanje napake
- Z matričnimi verzijami formul lahko gradiente računamo zelo učinkovito, za celo šaržo primerov naenkrat
- Število iteracij je število primerov deljeno z velikostjo šarže
- **Epoha** je en sprehod skozi celotno podatkovno množico

Plast skritih nevronov in nelinearnost pri klasifikaciji

Vhodna plast




Skrita plast (stanja nevronov)




Plast skritih nevronov in nelinearnost pri klasifikaciji

Vhodna plast



Skrita plast (izhodi nevronov)



Določanje strukture

Zaporedje plasti različnih tipov

- Običajna plast: **polno povezana** s prejšnjo
- Redka plast: polno povezana z **regularizacijo** uteži
- Običajni in redki plasti lahko dodelimo poljubno funkcijo aktivacije
- Konvolucijska plast: za obdelavo slik, implementira **konvolucijski filter**
- Akumulacijska plast: **združi** izhode nevronov iz prejšnje plasti

Konvolucijska, *convolution*, plast

Notacija


- Nevroni v plasti $l - 1$ organizirani v matriko dimenzij $x \times y$
- Uteži w_0 in **konvolucijska matrika** dimenzij $c \times c$, elementi $w_{i,j}$
- Plast l je matrika nevronov dimenzij $(x - c + 1) \times (y - c + 1)$

Konvolucija, uporabljena namesto običajne linearne obtežene vsote

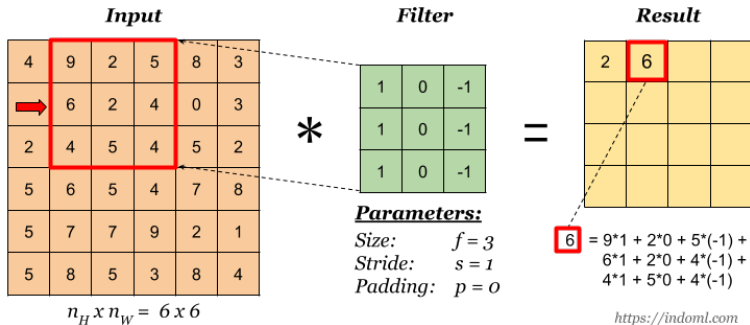
$$v_{i,j}^{(l)} = w_0 + \sum_{k=1}^c \sum_{m=1}^c w_{k,m} y_{i+k-1,j+m-1}^{(l-1)}$$

- $y_{i,j}^{(l-1)}$ in $v_{i,j}^{(l)}$ so izhodi in stanja nevronov v plasti $l - 1$ oz. l
- Običajna dimenzija konvolucijske matrike (tudi **filtra**) je $c = 5$

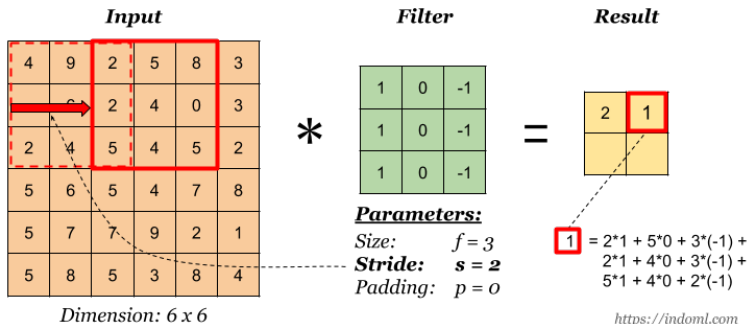
Konvolucijska plast: Grafični prikaz



Konvolucijska plast: Primer izračuna



Konvolucijska plast: Dodaten parameter korak, *stride*



Akumulacijska, *pooling*, plast

Notacija

- Nevroni v plasti $l - 1$ organizirani v matriko dimenzij $x \times y$
- Plast l je matrika nevronov dimenzij $(x/a) \times (y/a)$
- Predpostavka: $a|x$ in $a|y$


max-akumulacija, uporabljena namesto običajne linearne obtežene vsote

$$v_{i,j}^{(l)} = \max \left\{ y_{(i-1) \cdot a + 1, (j-1) \cdot a + 1}^{(l-1)}, \dots, y_{i \cdot a, j \cdot a}^{(l-1)} \right\}$$


- $y_{i,j}^{(l-1)}$ in $v_{i,j}^{(l)}$ so izhodi in stanja nevronov v plasti $l - 1$ oz. l
- Običajna vrednost $a = 2$

Raven akumulacije: Grafični prikaz

Raven nevronov I-1 (običajno izhodna raven konvolucije)




Raven nevronov I



Običajna topologija: $r \times$ konvolucija $\rightarrow r \times$ akumulacija

Uspešna uporaba za razpoznavanje z roko napisnih števil.



Nevronske mreže in grafi izračunov

Nevronska mreža določa graf izračuna funkcije

- Preslika vrednosti vhodnih spremenljivk X_i , $i = 1 \dots p$
- V vrednost izhodne/ izhodnih spremenljivk(e) Y

Struktura grafa izračuna GNM


Funkcija, ki

- Za podana vpetja vozlišč iz grafske sosesčine vozlišča v
- Izračuna vpetje v na izhodu


Bolj splošen pristop od običajnih vpetij, npr. node2vec

- Lahko izračuna vpetja za nova vozlišča, ki jih ni bilo v času učenja
- Lahko dobljena vpetja vgradimo v večjo nevronske mrežo
- Slednja lahko poskrbi za poljubno nalogo klasifikacije ali regresije


Od navadnega do grafa izračuna za vozlišče A




Graf izračuna globnine 2




Od navadnega do grafa izračuna za vozlišče B




Računski graf globnine 2



Od navadnega do grafa izračuna za vozlišče C



Računski graf globnine 2



Nevrnske mreže NM_l

Enotna struktura

- Izhod: vpetje **opazovanega vozlišča**
- Vhodi: vpetja **sosednjih vozlišč** v grafu

Težava in rešitev

- Težava: Spreminjajoče se število vhodov (sosednjih vozlišč)
- Rešitev: Akumulacijska plast združi vhode v vektor fiksne dolžine
- Združevanje mora biti **simetrično**, vrstni red argumentov brez vpliva
- Primer take funkcije združevanja je povprečje

Nevronske mreže NM_l in njihovo učenje

Večplastne nevronske mreže

- Akumulacijska plast, ki poskrbi za združevanje vhodov
- Ostale plasti so lahko poljubne, običajno kar polno povezane plasti

Različice osnovne strukture

- Grafske konvolucijske mreže, GCN
- GraphSAGE

Splošna struktura NM_l : Notacija

$$h^{(0)} = x_v$$
$$h_v^{(l+1)} = \phi \left(W_l \sum_{u \in \mathcal{N}(v)} \frac{h_u^{(l)}}{|\mathcal{N}(v)|} + B_l h_v^{(l)} \right)$$

- $h_v^{(l)}$ je izhodni vektor vpetja vozlišča v v plasti $l - 1$
- $l = 1, \dots, L - 1$, $h_v^{(L)}$ je **končno vpetje**
- x_v je vektor vrednosti vhodnih spremenljivk v vozlišču v
- ϕ je (nelinearna) funkcija aktivacije, aplicirana po komponentah
- W_l in B_l sta matriki parametrov nevronske mreže NM_l
- $\mathcal{N}(v)$ je množica sosedov vozlišča v v grafu

Splošna struktura NM_i : Pomen

$$h_v^{(l+1)} = \phi \left(w_l \sum_{u \in \mathcal{N}(v)} \frac{h_u^{(l)}}{|\mathcal{N}(v)|} + B_l h_v^{(l)} \right)$$

- Združevanje vhodov, t.j., vpetij sosednih vozlišč iz prejšnje plasti
- Vpetje vozlišča v iz prejšnje plasti
- ϕ poskrbi za nelinearno transformacijo vpetja
- Transformacija je očitno odvedljiva, ni težav z računanjem gradientov

Matrična verzija formule

$$H^{(l+1)} = \phi \left(D^{-1} A H^{(l)} W_l^T + H^{(l)} B_l^T \right)$$

- $H^{(l)}$ sta matriki vpetij učnih vozlišč grafa v plasteh $l - 1$ in l
- D je diagonalna matrika s stopnjami učnih vozlišč grafa
- A je matrika sosednosti učnih vozlišč grafa
- Funkcijo aktivacije ϕ apliciramo po elementih matrike
- Faktor $D^{-1}A$ poskrbi za izračun povprečja vpetij

Osnovna različica: Grafovske konvolucijske mreže, GCN

$$H^{(l+1)} = \phi \left(D^{-1} A H^{(l)} W_L^T \right)$$



- Ne upošteva vložitve opazovanega vozlišča iz prejšnje plasti
- Funkcija združevanja je lahko zgolj navadno povprečje

Različica GraphSAGE

$$H^{(l+1)} = \phi \left(\text{concat} \left(h_v^{(l)}, \text{agg}_{u \in \mathcal{N}(v)} \left(h_u^{(l)} \right) \right) W_l^T \right)$$

- Upošteva vložitev opazovanega vozlišča iz prejšnje plasti
- Funkcija združevanja je lahko poljubna, akumulacijska plast
- Običajno normaliziramo vpetja posameznih vozlišč na normo 1

Funkcija izgube: nadzorovani scenarij



Napovedovanje ciljne spremenljivke Y

- Primerjamo napoved $\hat{y}_v = f(h_v^{(L)})$ in vrednost y_v v vozlišču v
- f je nevronska mreža: vhod je vpetje vozlišča, izhod pa napoved Y
- Če je ciljna spremenljivka numerična, uporabimo kvadratno napako
- Če je ciljna spremenljivka diskretna, uporabimo prečno entropijo

Funkcija izgube: nenadzorovani scenarij

Napovedovanje razdalje med vozlišči, podobno kot node2vec

- Učni primeri ustrezajo parom vozlišč u in v
- Vrednosti vhodnih spremenljivk dobimo s stikom vpetij u in v
- Ciljna spremenljivka je 1, če sta u in v **podobna**, sicer 0
- Podobnost vozlišč dobimo s pomočjo bolj enostavne metode za vpetje

Odločitve pri sestavljanju GCN

Odločitve glede strukture

- Število plasti, koliko plasti sosesčin bomo uporabili
- Različica strukture GCN in funkcije združevanja
- Globina in struktura vsake plasti, NM_l

Funkcija izgube

- Nadzorovani ali nenadzorovani scenarij
- Opazovan objekt: vozlišče, povezava ali celoten graf

Težave pri sestavljanju GCN

Kako izbrati ustrezne globine?

- Če povečujemo število plasti, upoštevamo **preveliko soseščino**
- Če poglobljamo posamezne NM_l , tvegamo **preprileganje**

Kako izbrati ustrezne funkcije združevanja?

Oboje težavno, empirično primerjanje različnih možnosti za podatke.

Reference in implementacije

Uvod v grafske nevrnske mreže

- Začetek (Kipf in Welling 2017), [arXiv:1609.02907](https://arxiv.org/abs/1609.02907)
- Dober, ne preveč tehničen uvod, distill.pub/2021/gnn-intro/

Številne implementacije, priporočena knjižnica PyG

- Dostopna na pytorch-geometric.readthedocs.io ali pyg.org
- Vadnica v rubriki [Getting started/ Introduction by Example](#)